

UFPB

UNIVERSIDADE FEDERAL DA PARAÍBA
CENTRO DE CIÊNCIAS SOCIAIS APLICADAS
CIÊNCIAS DE DADOS PARA NEGÓCIOS
APRENDIZAGEM DE MÁQUINA SUPERVISIONADA

MARIA EDUARDA COSTA PEREIRA DE SOUZA
LETÍCIA SOUSA MOREIRA

PROFESSOR: ALÉSSIO TONY CAVALCANTI DE ALMEIDA

JOÃO PESSOA
2026

Relatório de Preparação dos Dados e Baseline de Machine Learning

Introdução

O projeto tem como objetivo desenvolver um experimento de Machine Learning Supervisionado voltado à previsão dos preços de revenda de combustíveis automotivos, utilizando dados públicos disponibilizados pela Agência Nacional do Petróleo, Gás Natural e Biocombustíveis (ANP).

A proposta surgiu a partir das necessidades identificadas na filial da Forno Nobre, localizada em João Pessoa, que enfrenta dificuldades no acompanhamento e na administração de seus custos operacionais, incluindo as despesas com combustíveis.

Diante da indisponibilidade dos dados internos da organização, optou-se pela utilização de dados públicos da ANP, que possibilitam analisar o comportamento dos preços praticados por diferentes estabelecimentos, considerando informações relacionadas à localização, ao tipo de combustível e às características das revendas.

O experimento busca estabelecer uma referência inicial para a previsão dos preços de revenda, utilizando registros históricos organizados cronologicamente e avaliando o desempenho das estimativas nos conjuntos de validação e teste.

Os resultados também poderão contribuir para a construção de um painel de Business Intelligence (BI), destinado ao acompanhamento das variações dos preços e ao apoio ao planejamento dos gastos com combustíveis.

É importante destacar que as previsões não representarão diretamente as despesas reais da Forno Nobre, mas estimativas dos preços praticados no mercado, que poderão servir como informações complementares para a tomada de decisão.

1. Contrato dos dados

1.1 Identificação e origem

- Base Utilizada:
- Dados de preços de combustíveis automotivos, disponibilizados publicamente pela Agência Nacional do Petróleo, Gás Natural e Biocombustíveis (ANP)

link da base de dados:https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/serie-historica-de-precos-de-combustiveis

- O conjunto de dados apresenta informações sobre os preços de revenda de combustíveis em diferentes municípios brasileiros, incluindo a identificação dos estabelecimentos, localização, tipo de combustível, data da coleta e valores praticados.

1.2 Unidade de análise e granularidade

A unidade de análise corresponde ao registro individual de preço de combustível coletado em um estabelecimento de revenda. Cada observação apresenta informações sobre o posto, o tipo de combustível comercializado, sua localização, a data da coleta e o respectivo valor de venda.

Para o desenvolvimento do experimento, foi mantida a granularidade original dos registros, sem agregação semanal dos preços. Dessa forma, cada linha da base processada representa uma observação individual de revenda, permitindo trabalhar com os diferentes combustíveis e localidades presentes no conjunto de dados.

1.3 Variável-Alvo

A variável-alvo selecionada foi *valor_de_venda*, correspondente ao preço de revenda do combustível registrado no estabelecimento no momento da coleta.

O experimento considera os valores individuais de venda dos diferentes combustíveis presentes na base da ANP, sem restringir a análise exclusivamente à gasolina comum.

A proposta consiste em avaliar a capacidade de previsão desses valores, estabelecendo inicialmente uma referência baseada na média dos preços observados no conjunto de treinamento.

1.4 Cobertura Temporal e Disponibilidade das Informações

A base utilizada apresenta registros de preços de combustíveis coletados em diferentes estabelecimentos do território nacional, abrangendo o período do primeiro semestre de 2024 ao primeiro semestre de 2026.

As datas de coleta foram utilizadas para organizar os registros cronologicamente, permitindo a separação dos dados em conjuntos de treinamento, validação e teste, respeitando a sequência temporal das observações.

A quantidade de registros varia entre os períodos, localidades e tipos de combustíveis, característica considerada na organização e preparação da base utilizada no experimento.

1.5 Restrições de uso

Por se tratar de uma base pública que apresenta preços praticados por diferentes estabelecimentos, os resultados deverão ser interpretados como estimativas do comportamento médio dos preços de mercado.

As previsões não representarão diretamente os valores pagos pelo gestor da empresa, uma vez que não serão utilizados dados internos de abastecimento da organização.

Dessa forma, a aplicação da ferramenta deverá considerar essa limitação, utilizando as previsões como informações complementares para o planejamento dos gastos com combustíveis.

1.6 Atualização e Cobertura de Base

A base foi obtida a partir dos dados públicos disponibilizados pela ANP, abrangendo o período do primeiro semestre de 2024 ao primeiro semestre de 2026, com registros de preços de combustíveis automotivos em diferentes municípios e estados brasileiros.

Os dados apresentam informações sobre os estabelecimentos pesquisados, produtos comercializados, preços de revenda e respectivas datas de coleta.

Embora a base tenha uma abrangência nacional, a quantidade de registros pode variar entre as localidades e os períodos analisados. Essa característica deverá ser considerada na preparação dos dados e na definição do recorte utilizado para o modelo preditivo.

2. Auditoria e preparação dos dados

A auditoria inicial foi realizada sobre os cinco arquivos semestrais da ANP, referentes ao período de janeiro de 2024 a junho de 2026.

Após a unificação dos arquivos, a base apresentou 2.134.685 registros e 16 colunas. A inspeção contemplou a estrutura das variáveis, os tipos de dados, a presença de valores ausentes, a identificação de duplicidades e a consistência das informações registradas.

Foram identificados 9.129 registros completamente duplicados, posteriormente removidos durante a limpeza. Também foram realizados procedimentos de padronização das colunas, conversão de tipos de dados e tratamento das informações utilizadas nas etapas seguintes.

2.1 Valores ausentes e tratamento das informações

A inspeção inicial contemplou a identificação de valores ausentes nas 16 variáveis da base unificada, considerando os campos relacionados à identificação dos estabelecimentos, localização, produto, data da coleta e preços de revenda.

Durante a limpeza, a variável *valor_de_venda* foi convertida para o formato numérico, com substituição das vírgulas por pontos e utilização de *errors='coerce'* para tratar valores incompatíveis com a conversão.

As informações de identificação e localização também passaram por procedimentos de padronização, incluindo o tratamento do CNPJ, CEP e campos textuais.

Na etapa de transformação, foi aplicado um filtro para manter exclusivamente os registros com *valor_de_venda* superior a zero, resultando na exclusão de um registro adicional.

2.2 Padronização e Duplicidades

A preparação dos dados contemplou a padronização dos nomes das colunas para letras minúsculas, com substituição dos espaços por underscores, seguindo o padrão *snake_cas*e.

Também foram realizados ajustes nos formatos das variáveis, incluindo a conversão de *valor_de_venda* para numérico, a padronização das datas de coleta e o tratamento das informações textuais e de identificação dos estabelecimentos.

Na inspeção inicial, foram identificados 9.129 registros completamente duplicados, correspondentes a aproximadamente 0,43% das observações da base original.

Esses registros foram removidos por meio do método *drop_duplicates()*, reduzindo a base de 2.134.685 para 2.125.556 observações, sem alteração na quantidade original de 16 colunas.

2.3 Distribuição da Variável-Alvo

A variável-alvo corresponde ao *valor_de_venda,* representando os preços individuais de revenda dos combustíveis registrados na base da ANP. Após os procedimentos de limpeza e transformação, a base apresentou 2.125.555 registros, considerando os

diferentes combustíveis e localidades analisados.

A análise descritiva foi realizada considerando a distribuição dos preços por região brasileira e tipo de combustível, contemplando a quantidade de observações, os valores médios, medianos, mínimos e máximos, além do desvio-padrão.

Resultados da análise descritiva:

Preços Médios de revenda por região e combustível (R$):

Região	Diesel	Diesel S10	Etanol	Gasolina	Gasolina aditivada	GNV
Centro-Oeste	6,15	6,23	4,17	6,19	6,35	4,26
Norte	6,62	6,61	4,94	6,61	6,80	4,79
Nordeste	6,23	6,22	4,76	6,27	6,41	4,72
Sul	6,15	6,25	4,52	6,23	6,39	4,88
Sudeste	6,12	6,24	4,12	6,05	6,30	4,68

Os resultados indicam diferenças nos preços médios de revenda entre as regiões brasileiras. A região Norte apresentou os maiores preços médios para diesel (R$ 6,62), diesel S10 (R$ 6,61), etanol (R$ 4,94), gasolina (R$ 6,61) e gasolina aditivada (R$ 6,80). Para o GNV, o maior preço médio foi registrado na região Sul (R$ 4,88).

Em contrapartida, a região Sudeste apresentou os menores preços médios de gasolina (R$ 6,05), gasolina aditivada (R$ 6,30), etanol (R$ 4,12) e diesel (R$ 6,12).

Em relação à dispersão, o diesel S10 apresentou o maior desvio-padrão na região Norte (R$ 0,66), seguido pelo diesel no Nordeste (R$ 0,61) e pela gasolina no Norte (R$ 0,60). A menor dispersão foi observada no GNV da região Sul, com desvio-padrão de R$ 0,29.

A análise também evidenciou diferenças na quantidade de registros entre as regiões. O Sudeste apresentou a maior concentração de observações, especialmente para gasolina (264.877 registros) e etanol (252.264 registros), enquanto o Norte apresentou quantidades menores para esses combustíveis.

De modo geral, os resultados demonstram diferenças regionais nos preços de revenda, tanto em relação aos valores médios quanto à dispersão observada. Essas características deverão ser consideradas na interpretação do desempenho do modelo, especialmente diante da diversidade de combustíveis e da distribuição desigual dos registros entre as regiões.

2.4 Relatório de Qualidade dos Dados

Variável/base	**Problema identificado**	**Decisão aplicada**	**Impacto/Validação**
Valor de Venda	Formatação decimal e presença de valor não positivo	Conversão para numérico e exclusão de preços ≤ 0	Remoção de 1 registro na transformação
Data de coleta	Necessidade de padronização do formato	Conversão para *datetime*, considerando dia, mês e ano	Utilizada na ordenação cronológica
Produto	Necessidade de uniformização textual	Padronização dos campos de texto para letra minúsculas	Uniformização das categorias
Base completa	9129 registros duplicados	Remoção com *drop_duplicates()*	Redução de 2.134.685 para 2.125.556 registros
CNPJ e CEP	Presença de caracteres especiais	Remoção de caracteres não numéricos	Padronização dos identificadores
unidade_de_medida	Diferenças na representação das unidade	Substituição de *m3* por *m³*	Uniformização da nomenclatura
Variáveis textuais	Presença de valores ausentes	Preenchimento com *não consta*	Tratamento dos campos incompletos
Variáveis numéricas	Presença de valores ausentes	Preenchimento com zero	Tratamento aplicado na limpeza

2.5 Validação da Base Processada

A base processada foi construída a partir da unificação dos cinco arquivos semestrais da ANP, abrangendo o período de janeiro de 2024 a junho de 2026.

Inicialmente, o conjunto apresentou 2.134.685 registros e 16 colunas. Após a identificação e remoção de 9.129 registros duplicados, a base passou a conter 2.125.556 observações.

Na etapa de transformação, foi aplicado o filtro para manutenção de preços de venda superiores a zero, resultando em 2.125.555 registros.

Também foram criadas quatro variáveis derivadas: *ano_coleta, mes_coleta, tipo_bandeira e faixa_de_preco*, ampliando a estrutura original de 16 para 20 colunas.

Adicionalmente, foi construída uma visão agregada por estado e produto, contemplando os preços médios, medianos, mínimos e máximos, além da quantidade de estabelecimentos distintos.

A análise descritiva também foi organizada por região brasileira e tipo de combustível, permitindo comparar os preços e sua dispersão entre as cinco regiões do país.

A base transformada foi exportada para o arquivo *base_anp_transformada.csv,* no diretório dados/processado, preservando os 2.125.555 registros e as 20 colunas resultantes do processamento.

3. Diagnóstico de vazamento de informação

Variável	Permitida?	Justificativa
valor_de_venda	Não	Corresponde à variável-alvo que será prevista
faixa_de_preco	Não	Foi construída diretamente a partir de *valor_de_venda,* antecipando informações da variável-alvo
data_da_coleta	Sim, com restrições	Pode ser utilizada para organizar os registros e construir variáveis temporais conhecidas no momento da previsão
ano_coleta	Sim	Derivada da data de coleta, desde que conhecida no momento da previsão
mes_coleta	Sim	Derivada da data de coleta, desde que conhecida no momento da previsãol
produto	Sim	Identifica o tipo de combustível registrado
estado_sigla	Sim	Informação geográfica conhecida previamente
regiao_sigla	Sim	Identifica a região brasileira do estabelecimento
tipo_bandeira	Sim	Classificação do estabelecimento conforme a sua bandeira
cnpj_da_revenda	Condicional	Pode identificar estabelecimentos, mas exige cuidado para não utilizar informações futuras ou memorizar registros específicos

3.2 Riscos Identificados e Decisões Adotadas

A análise das variáveis identificou um risco de vazamento de informação relacionado à variável *faixa_de_preco*, construída a partir dos valores da própria variável-alvo *(valor_de_venda)*. Sua utilização como preditora permitiria que informações diretamente relacionadas ao preço observado fossem incorporadas ao processo de previsão.

Embora essa variável esteja presente no conjunto de características preparado para a modelagem, o baseline implementado utiliza exclusivamente a média da variável-alvo calculada no conjunto de treinamento, não incorporando as demais características na geração das previsões.

Para o particionamento, os registros foram ordenados pela data de coleta e separados sequencialmente em treinamento, validação e teste, sem embaralhamento aleatório.

Entretanto, foram identificadas datas compartilhadas entre os conjuntos nos limites das divisões, uma vez que o particionamento foi realizado pela quantidade de registros. Essa característica representa uma limitação da separação temporal implementada.

Dessa forma, a utilização de *faixa_de_preco* deverá ser excluída das variáveis preditoras em modelos posteriores, assim como deverá ser considerada a separação dos conjuntos por datas distintas para evitar sobreposições temporais.

4. Estratégia de partição dos Dados

A base transformada, composta por 2.125.555 registros, foi dividida em três conjuntos: treinamento (70%), validação (15%) e teste (15%).

O particionamento foi realizado após a ordenação dos registros pela variável *data_da_coleta*, utilizando a função *train_test_split()* com o parâmetro *shuffle=False*, preservando a sequência cronológica das observações.

A distribuição dos registros ocorreu da seguinte forma:

Conjunto	Percentual	Registros	Período
Treinamento	70%	1.487.888	01/01/2024 a 24/09/2025
Validação	15%	318.833	24/09/2025 a 16/02/2026
Teste	15%	318.834	16/02/2026 a 30/06/2026
Total	100%	2.125.555	01/01/2024 a 30/06/2026

O conjunto de treinamento foi composto pelos registros mais antigos, enquanto a validação e o teste receberam as observações posteriores. Essa organização permitiu avaliar o desempenho do modelo em períodos diferentes daquele utilizado para seu treinamento.

Entretanto, a divisão foi realizada pela quantidade de registros, resultando no

compartilhamento das datas de 24/09/2025 e 16/02/2026 entre conjuntos consecutivos. Embora não tenha ocorrido embaralhamento, essa característica representa uma limitação do particionamento temporal, pois registros de uma mesma data foram distribuídos entre conjuntos distintos.

Além disso, a quantidade de observações varia entre as regiões e os tipos de combustíveis, aspecto que deverá ser considerado na interpretação dos resultados, especialmente diante das diferenças regionais identificadas na análise descritiva.

5. Pré-Processamento dos Dados

O pré-processamento foi realizado sobre os registros de preços de combustíveis disponibilizados pela ANP, abrangendo o período de janeiro de 2024 a junho de 2026.

Inicialmente, foram executados procedimentos de limpeza e normalização, incluindo a remoção de duplicidades, padronização dos nomes das colunas, conversão dos preços de venda para valores numéricos, tratamento de informações ausentes e adequação dos formatos das datas.

Posteriormente, foram aplicadas transformações para ampliar as possibilidades de análise dos dados, considerando características temporais, informações dos estabelecimentos e classificações dos preços de revenda.

Após esses procedimentos, a base transformada apresentou 2.125.555 registros e 20 colunas, sendo utilizada nas etapas de particionamento e construção do baseline.

5.1 Transformações aplicadas

A transformação dos dados foi realizada a partir da base previamente limpa e normalizada, contemplando os seguintes procedimentos:

1. Filtragem dos preços de venda

Foram mantidos exclusivamente os registros com *valor_de_venda* superior a zero, resultando na exclusão de uma observação e na redução da base para 2.125.555 registros.

2. Criação das variáveis temporais

A partir da variável *data_da_coleta*, foram criadas as colunas *ano_coleta* e *mes_coleta*, contendo, respectivamente, o ano e o mês de cada observação.

3. Classificação dos estabelecimentos

Foi criada a variável tipo_bandeira, classificando os estabelecimentos em duas categorias:

- *independente:* postos identificados com bandeira branca
- *rede_franqueada:*

4. Classificação dos preços

Foi criada a variável *faixa_de_preco*, utilizando a função *pd.qcut()* para distribuir os valores de venda em três categorias: baixo, médio e alto.

A classificação foi realizada a partir da distribuição dos preços observados na base transformada.

5. Construção da visão agregada

Foi criada uma base complementar agrupada por *estado_sigla* e produto, contemplando os preços médios, medianos, mínimos e máximos, além da quantidade de estabelecimentos distintos.

Adicionalmente, foi realizada uma análise descritiva por *regiao_sigla* e produto, incorporando a quantidade de observações e o desvio-padrão dos preços, conforme apresentado na seção 2.3.

Ao final das transformações, a base principal apresentou 20 colunas, incluindo as quatro variáveis derivadas, e foi exportada para o arquivo *base_anp_transformada.csv.*

5.2 Controle de vazamento no pré-processamento

O controle temporal foi realizado por meio da ordenação dos registros pela variável *data_da_coleta*, seguida do particionamento sequencial dos conjuntos de treinamento, validação e teste, sem embaralhamento aleatório.

Na preparação das variáveis para a modelagem, a coluna *valor_de_venda* foi separada como variável-alvo, enquanto as demais colunas permaneceram no conjunto de características.

Entretanto, a variável *faixa_de_preco*, construída diretamente a partir de *valor_de_venda*, permaneceu entre as características disponíveis. Essa condição representa um risco de vazamento de informação para modelos que utilizem essas variáveis como preditoras.

No baseline implementado, esse risco não influenciou diretamente as previsões, uma vez que o *DummyRegressor* utilizou exclusivamente a média da variável-alvo calculada no conjunto de treinamento.

Também foi identificada a presença de datas compartilhadas entre os conjuntos de treinamento, validação e teste, decorrente da divisão sequencial por quantidade de registros.

Dessa forma, embora a implementação tenha preservado a ordenação cronológica e utilizado exclusivamente os valores de treinamento para o ajuste do baseline, permanecem limitações relacionadas à construção das variáveis e à separação temporal, que deverão ser corrigidas antes da aplicação de modelos preditivos que utilizem as características dos registros.

6. Baseline e Avaliação Inicial

6.1 Baseline de Referência

O baseline foi implementado utilizando o modelo *DummyRegressor*, configurado com a estratégia mean, considerando a média aritmética da variável-alvo *valor_de_venda*.

O modelo foi ajustado exclusivamente com os 1.487.888 registros do conjunto de treinamento, correspondentes ao período de 01/01/2024 a 24/09/2025.

A média obtida foi de R$ 5,68, utilizada como previsão constante para todos os registros dos conjuntos de validação e teste, independentemente do tipo de combustível, região ou estabelecimento.

Essa abordagem foi adotada como referência inicial para a comparação com modelos preditivos posteriores.

6.2 Resultados da Avaliação Inicial

A avaliação do baseline foi realizada nos conjuntos de validação e teste, utilizando as métricas MAE e RMSE.

Métrica	Validação	Teste
MAE	R$ 0,7079	R$ 1,1399
RMSE	R$ 0,8454	R$ 1, 2599

No conjunto de validação, composto por 318.833 registros, o modelo apresentou MAE de R$ 0,7079 e RMSE de R$ 0,8454.

No conjunto de teste, composto por 318.834 registros, o MAE aumentou para R$ 1,1399, enquanto o RMSE atingiu R$ 1,2599.

Os resultados demonstram um aumento dos erros entre os períodos de validação e teste. O MAE apresentou crescimento de aproximadamente 61%, enquanto o RMSE aumentou cerca de 49%.

Esse comportamento evidencia diferenças no desempenho da previsão constante entre os períodos avaliados, indicando limitações da utilização de uma única média para representar os preços de diferentes combustíveis, regiões e momentos da coleta.

6.3 Métrica de avaliação

A métrica principal adotada para avaliação do experimento foi o Erro Médio Absoluto (MAE), considerando a necessidade de avaliar as diferenças entre os preços previstos e os valores efetivamente registrados na base da ANP.

Como métrica complementar, foi utilizado o RMSE, permitindo observar a influência de erros de maior magnitude sobre o desempenho das previsões.

No conjunto de teste, o baseline apresentou MAE de R$ 1,1399 e RMSE de R$ 1,2599, estabelecendo os resultados de referência para a avaliação dos modelos posteriores.

Dessa forma, o MAE de R$ 1,1399 foi estabelecido como referência inicial de desempenho no conjunto de teste. Modelos posteriores deverão apresentar erros inferiores aos registrados pelo baseline, considerando a mesma base de avaliação e as mesmas condições de comparação.

A avaliação realizada não incorporou informações sobre o consumo efetivo de combustíveis ou os valores gastos pela Forno Nobre, permanecendo restrita à previsão dos preços individuais de revenda registrados pela ANP.

7. Limitações

A principal limitação do projeto está relacionada à utilização de dados públicos da ANP para investigar um problema identificado no contexto operacional da Forno Nobre. Embora os registros permitam analisar os preços praticados no mercado, eles não representam diretamente os valores pagos pela organização, nem incorporam informações sobre consumo, frequência de abastecimento ou despesas efetivas.

Outra limitação está relacionada à diversidade de combustíveis e localidades presentes na base. Conforme observado na análise descritiva, os preços apresentam diferenças entre regiões e produtos, enquanto o baseline implementado utiliza uma única média para todos os registros, sem considerar essas características.

Em relação ao particionamento, a divisão cronológica foi realizada pela quantidade de observações, resultando no compartilhamento de datas entre os conjuntos de treinamento, validação e teste. Embora a ordem dos registros tenha sido preservada, essa estratégia não garante a separação completa dos períodos.

Também foi identificado um risco de vazamento de informação associado à variável *faixa_de_preco*, construída diretamente a partir da variável-alvo. Apesar de não influenciar as previsões do *DummyRegressor*, sua permanência entre as características disponíveis representa uma restrição para a implementação de modelos posteriores.

Além disso, o experimento não incorporou variáveis históricas defasadas ou outras características temporais destinadas à previsão de preços futuros. Dessa forma, os resultados obtidos representam uma avaliação inicial baseada na média dos registros de treinamento, não permitindo estabelecer conclusões sobre a capacidade de antecipar oscilações futuras dos preços.

A aplicação da solução no contexto da Forno Nobre dependerá da avaliação de sua utilidade para o planejamento financeiro e, eventualmente, da disponibilidade de dados internos que permitam relacionar os preços de mercado aos gastos efetivos da organização.

8. Declaração do Uso de IA Generativa

Durante o desenvolvimento do projeto, foi utilizada a ferramenta ChatGPT, desenvolvida pela OpenAI, como apoio à organização e revisão textual do relatório, além de auxiliar na compreensão e no tratamento dos dados durante a implementação dos códigos.

Na documentação, a ferramenta contribuiu com sugestões de estruturação e redação das seções metodológicas. Na etapa de programação, foi utilizada para esclarecer dúvidas sobre variáveis e dados menos familiares à equipe, orientar procedimentos de manipulação e tratamento dessas informações e auxiliar na compreensão de sua aplicação no código.

9. Verificações individuais

Verificação Individual- Leticia Sousa Moreira

1. **Variável Permitida- *produto***

A identificação do tipo de combustível pode ser utilizada como preditora, desde que essa informação esteja disponível no momento da previsão.

2. **Variável proibida por vazamento temporal- *data_da_coleta* (uso condicionado ao corte temporal)**

A data da coleta não representa, isoladamente, um vazamento. Entretanto, utilizá-la para incorporar informações de preços registrados após o momento da previsão caracterizaria vazamento temporal.

3. **Variável proibida por ser consequência da decisão- Não identificada na base**

A base da ANP registra preços de revenda, sem apresentar resultados de decisões de abastecimento da Forno Nobre. Portanto, não foi identificada uma variável real que se enquadre nessa categoria.

Verificação Individual- Maria Eduarda Costa Pereira de Souza

1. **Variável Permitida- *regiao_sigla***

A variável identifica a região brasileira do estabelecimento e pode ser utilizada como preditora, pois a localização é conhecida previamente à previsão do preço.

2. **Variável proibida por vazamento temporal- *valor_de_venda* (observações posteriores ao corte)**

Os valores de venda registrados após a data de referência não podem ser utilizados para construir características de uma previsão anterior, pois representam informações futuras indisponíveis naquele momento.

3. **Variável proibida por ser consequência da decisão- Não identificada na base**

Os registros utilizados não incluem informações sobre intervenções ou decisões operacionais tomadas pela organização. Assim, não foi identificada uma variável que represente uma consequência posterior dessas decisões.

Anexos e Documentação Complementar

Repositório do projeto:
https://github.com/M-Eduarda-Souza/analise-de-combustiveis/tree/main

Notebook principa**l:**
https://github.com/M-Eduarda-Souza/analise-de-combustiveis/blob/main/notebooks/auditoria_dados.ipynb