

UFPB

UNIVERSIDADE FEDERAL DA PARAÍBA
CENTRO DE CIÊNCIAS SOCIAIS APLICADAS
CIÊNCIAS DE DADOS PARA NEGÓCIOS
APRENDIZAGEM DE MÁQUINA SUPERVISIONADA

MARIA EDUARDA COSTA PEREIRA DE SOUZA
LETÍCIA SOUSA MOREIRA

PROFESSOR: ALÉSSIO TONY CAVALCANTI DE ALMEIDA

JOÃO PESSOA
2026

1. Decisão

O projeto foi desenvolvido para apoiar a tomada de decisão do gerente da filial Forno Nobre, localizada em João Pessoa, no acompanhamento dos preços da gasolina comum e no planejamento das despesas com abastecimento. Atualmente, os gastos são registrados a partir dos comprovantes apresentados pelos motoristas e posteriormente lançados em planilhas financeiras, sem um acompanhamento específico das variações dos preços dos combustíveis.

A solução proposta busca fornecer estimativas de preços que auxiliem o demandante na análise dos custos de abastecimento, com utilização periódica ou conforme as necessidades operacionais da filial. Considerando que o responsável administra simultaneamente diferentes áreas da organização e possui maior familiaridade com planilhas, a ferramenta deverá apresentar resultados claros e de fácil interpretação, funcionando como apoio à decisão, sem substituir a avaliação do gestor.

2. Formulação

O projeto foi estruturado como um problema de regressão supervisionada, tendo como unidade de análise cada registro de preço de revenda de combustível disponibilizado pela Agência Nacional do Petróleo, Gás Natural e Biocombustíveis (ANP). A população considerada corresponde aos registros coletados no Brasil, entre janeiro de 2024 e junho de 2026, contemplando diferentes localidades, produtos e características dos estabelecimentos.

A variável-alvo é o preço de venda do combustível, expresso em reais por litro *(valor_de_venda)*, estimado a partir das características disponíveis em cada registro. Embora a necessidade operacional identificada junto ao demandante considere um horizonte de uma semana à frente, o primeiro modelo desenvolvido estima preços a partir das informações associadas aos registros, sem implementar diretamente esse horizonte semanal.

O corte temporal adotado preserva a ordem cronológica dos dados, destinando os registros mais antigos ao treinamento e os períodos posteriores à validação e ao teste, permitindo avaliar o desempenho do modelo em observações temporalmente posteriores.

A arquitetura de processamento e a geração das predições operam estritamente na granularidade original do conjunto de dados, analisando as informações em nível de registro individual. O algoritmo empregado processa as variáveis independentes (*features*) disponíveis no exato instante de cada aferição para estimar o preço de revenda correspondente àquela mesma observação.

A modelagem estruturada não aplica agregações temporais, como consolidações semanais, nem utiliza técnicas de deslocamento de variáveis (*shifts* ou *lags*) para projetar valores matematicamente futuros na mesma linha de dados. A árvore de decisão avalia o cenário de cada registro de forma isolada e síncrona, garantindo que a estimativa gerada reflita fielmente as condições pontuais do mercado, cabendo à etapa de análise do gestor a consolidação dessas predições individuais para o horizonte operacional desejado.

3. Dados

Foram utilizados dados públicos da Agência Nacional do Petróleo, Gás Natural e Biocombustíveis (ANP), referentes aos preços de revenda de combustíveis no Brasil, no período de janeiro de 2024 a junho de 2026. A base contempla informações sobre localização dos estabelecimentos, tipo de combustível, bandeira da revenda, data da coleta e preço de venda.

A preparação dos dados envolveu a padronização dos nomes das colunas, adequação dos tipos de dados, tratamento de valores ausentes e exclusão de registros com datas inválidas ou preços não positivos. Também foram criadas variáveis referentes ao ano e mês da coleta e à classificação das bandeiras dos estabelecimentos.

Para a modelagem, foram selecionadas as características geográficas, o produto, a bandeira, o tipo de bandeira e as informações temporais. Variáveis derivadas diretamente do preço de venda foram excluídas das entradas do modelo, evitando a utilização direta de informações da variável-alvo.

Como limitação, destaca-se que os dados representam preços de revenda coletados pela ANP, não correspondendo necessariamente aos valores efetivamente pagos pela organização em seus abastecimentos.O balanço da auditoria e preparação do dataset é o seguinte:

Volumetria de Registros:

- Quantidade inicial: 2.134.685 linhas.
- Quantidade final: 2.125.555 linhas.
- Registros removidos: 9.130 linhas no total, sendo 9.129 duplicatas exatas e 1 registro removido por data ou preço ausente ou não positivo.

Problemas de Qualidade: Os principais problemas identificados durante a auditoria envolveram 9.129 ocorrências de linhas duplicadas, a variável Valor de Compra apresentando 100% de valores ausentes, um alto índice de dados faltantes (mais de 77%) na coluna Complemento, além de um caso isolado com preço não positivo.

Valores Ausentes na Modelagem: As variáveis valor_de_compra, complemento, bairro e numero_rua permaneceram com dados ausentes na base final. Entretanto, essas variáveis não foram selecionadas como entradas do primeiro modelo. Para as variáveis efetivamente utilizadas na modelagem, o tratamento de valores ausentes foi realizado dentro do Pipeline, utilizando uma categoria constante para as variáveis categóricas e a mediana para as variáveis numéricas.

4. Partição

Para a divisão dos dados, utilizamos uma partição temporal, separando aproximadamente 70% das datas para treino, 15% para validação e 15% para teste. Essa divisão foi realizada considerando as datas distintas da base, garantindo que os registros de um mesmo dia permanecessem no mesmo conjunto.

O conjunto de treino ficou com 1.504.362 registros, referentes ao período de 01/01/2024 a 01/10/2025. A validação contou com 302.446 registros, de 02/10/2025 a 16/02/2026, enquanto o teste reuniu 318.747 registros, de 17/02/2026 a 30/06/2026.

Escolhemos essa estratégia para respeitar a ordem cronológica dos dados, utilizando os registros mais antigos para treinar o modelo e os períodos seguintes para avaliar seu desempenho. Dessa forma, conseguimos analisar como o modelo se comporta diante de informações de períodos que não foram utilizados no treinamento.

5. Baselines

Para termos uma referência inicial do desempenho do modelo, utilizamos dois baselines: um trivial e outro operacional proposto.

O baseline trivial foi desenvolvido com o *DummyRegressor,* utilizando a média dos preços de venda do conjunto de treino como previsão para os demais registros. No conjunto de teste, apresentou MAE de R$ 1,1393 e RMSE de R$ 1,2593.

Já o baseline operacional proposto utilizou a mediana histórica dos preços, considerando o estado e o tipo de combustível. Os valores foram calculados apenas com os dados de treino e, para combinações não encontradas nesse conjunto, utilizamos a mediana geral como referência. Essa abordagem apresentou MAE de R$ 0,7124 e RMSE de R$ 0,8582.

Ao comparar os resultados, observamos que o baseline operacional apresentou erros menores que o trivial, mostrando que considerar o estado e o tipo de combustível contribuiu para melhorar as estimativas.

6. Modelo

Para o primeiro modelo supervisionado, utilizamos o algoritmo DecisionTreeRegressor, configurado com profundidade máxima de 10 níveis (max_depth=10) e semente aleatória 42 (random_state=42). Foram utilizadas como variáveis preditoras a região, o estado, o produto, a bandeira, o tipo de bandeira, o ano e o mês da coleta.

A preparação dos dados foi implementada por meio de um Pipeline, associado a um ColumnTransformer. Para as variáveis categóricas, foi realizada a imputação dos valores ausentes por uma categoria constante, seguida da codificação com OneHotEncoder. Para as variáveis numéricas, foi utilizada a imputação dos valores ausentes pela mediana. Essas etapas foram organizadas dentro do Pipeline, garantindo que os ajustes das transformações fossem realizados exclusivamente com os dados disponíveis em cada etapa de treinamento.

A avaliação do modelo também contou com validação cruzada temporal, utilizando cinco divisões (TimeSeriesSplit, com n_splits=5). O procedimento foi organizado com base nas datas distintas dos registros, mantendo as observações de um mesmo dia no mesmo grupo. A validação foi realizada sobre os dados de treinamento, utilizando o MAE como métrica de avaliação.

O modelo apresentou MAE médio de R$ 0,2866 e desvio-padrão de R$ 0,0638 entre os cinco folds.

Em relação à configuração do algoritmo, foi utilizada uma definição fixa dos parâmetros para esta primeira versão do modelo. Não foi implementada uma busca automatizada de hiperparâmetros, como GridSearchCV ou RandomizedSearchCV. Dessa forma, os resultados representam uma avaliação inicial da árvore de decisão, sem afirmar que sua configuração corresponde à combinação ótima de parâmetros.

Consideramos que as características geográficas, o tipo de combustível, a bandeira e o período da coleta possuem relação com as diferenças observadas nos preços de venda. Entretanto, essas relações podem variar ao longo do tempo, principalmente diante de mudanças nas condições do mercado.

7. Avaliação

Para avaliar os resultados, utilizamos o MAE como métrica principal e o RMSE como métrica secundária. A escolha do MAE foi feita por permitir uma interpretação mais direta dos erros em reais por litro, facilitando a comparação entre os preços previstos e os valores reais.

Também consideramos os custos dos erros para a organização. Durante a escuta do demandante, identificamos que antecipar abastecimentos sem necessidade pode comprometer recursos que seriam utilizados em outras atividades da filial. Por isso, além do erro médio, consideramos importante acompanhar os erros de maior magnitude por meio do RMSE.

Consideramos o custo B como o prejuízo de antecipar abastecimentos sem necessidade, caso o modelo indique um aumento de preço que não aconteça. Já o custo C está relacionado à ausência de preparação para um aumento que realmente ocorra. Na escuta do demandante, identificamos inicialmente que o custo B pode representar um impacto maior para a organização, devido ao comprometimento desnecessário de recursos financeiros. Entretanto, esses custos ainda não foram quantificados.

Comparação dos resultados no conjunto de teste

Abordagem	MAE (R$)	RMSE (R$)
Baseline Trivial	1,1393	1,2593
Baseline operacional proposto	0,7124	0,8582
Árvore de decisão	0,5507	0,6993

Ao comparar os resultados, observamos que a árvore de decisão apresentou o melhor desempenho, reduzindo o MAE em aproximadamente 22,7% em relação ao baseline operacional e 51,7% em relação ao trivial.

Na validação cruzada temporal, o modelo apresentou MAE médio de R$ 0,2866, com desvio-padrão de R$ 0,0638 entre os cinco folds. Já no conjunto de teste, o MAE foi de R$ 0,5507, indicando um aumento do erro em relação aos períodos utilizados na validação cruzada.

Apesar desse aumento, o modelo continuou apresentando resultados superiores aos dois baselines no conjunto de teste.

8. Diagnóstico

Para analisar os erros do modelo, calculamos os resíduos a partir da diferença entre os preços reais e os valores previstos no conjunto de teste. Também avaliamos a distribuição desses resíduos, a relação entre os preços reais e previstos e as dez observações com maiores erros absolutos.

Os resultados apresentaram média dos resíduos de R$ 0,4502, mediana de R$ 0,4099 e desvio-padrão de R$ 0,5351. O maior erro absoluto identificado foi de R$ 3,7099.

Como a média e a mediana dos resíduos foram positivas, observamos uma tendência de o modelo prever preços abaixo dos valores reais. Além disso, a presença de erros mais elevados em algumas observações mostra que o modelo ainda apresenta dificuldades para acompanhar determinadas variações dos preços.

Entre as observações com maiores erros absolutos, identificamos registros em que o preço real chegou a R$ 9,99, enquanto a previsão do modelo foi de R$ 6,2801, resultando em uma diferença de R$ 3,7099. Esse comportamento mostra que o modelo apresentou maior dificuldade em algumas observações com preços elevados, produzindo estimativas abaixo dos valores registrados.

Esses resultados indicam que, mesmo apresentando desempenho superior aos baselines, o modelo ainda possui limitações que precisam ser consideradas antes de sua utilização nas decisões da organização.

9. Limitações

Apesar dos resultados obtidos, identificamos algumas limitações que precisam ser consideradas na aplicação do modelo. A primeira está relacionada aos dados utilizados, que representam preços de revenda

coletados pela ANP em diferentes regiões do Brasil, não correspondendo necessariamente aos valores efetivamente pagos pela filial em seus abastecimentos.

Outra limitação está relacionada às variáveis selecionadas para a modelagem. Embora a base original contenha informações mais detalhadas sobre os estabelecimentos, como município, bairro e identificação da revenda, o primeiro modelo utiliza apenas região, estado, produto, bandeira, tipo de bandeira, ano e mês da coleta. Dessa forma, não consegue representar diferenças específicas entre postos de uma mesma localidade, limitando a precisão das estimativas para estabelecimentos individuais.

Também foram identificadas limitações na qualidade e disponibilidade das informações. A variável valor_de_compra apresenta 100% de valores ausentes, enquanto a coluna complemento possui mais de 77% de ausência. Além disso, existem registros sem informações de bairro e número da rua. Essas variáveis não foram utilizadas como preditoras no primeiro modelo, mas sua ausência restringe a possibilidade de análises mais detalhadas sobre as características dos estabelecimentos e seus custos.

Em relação ao comportamento temporal, o modelo utiliza apenas o ano e o mês da coleta como informações relacionadas ao tempo, sem incorporar variáveis de preços anteriores, tendências recentes ou médias históricas semanais. Por esse motivo, ainda não consegue acompanhar adequadamente todas as oscilações de curto prazo do mercado, nem realizar diretamente a previsão de preços para uma semana à frente.

Além disso, observamos uma redução do desempenho na avaliação de períodos posteriores ao treinamento. Enquanto a validação cruzada temporal apresentou MAE médio de R$ 0,2866, o conjunto de teste apresentou MAE de R$ 0,5507. Os resíduos também indicaram uma tendência de subestimação dos preços, especialmente em algumas observações com valores elevados. Esse comportamento demonstra que o modelo pode apresentar maior dificuldade diante de mudanças nas condições do mercado.

Por fim, o modelo não considera informações específicas da organização, como consumo dos veículos, rotas de entrega, quantidade de combustível utilizada e valores efetivamente pagos nos abastecimentos. Por isso, seus resultados ainda não permitem estimar diretamente os gastos totais da filial ou determinar com segurança o melhor momento para abastecer.

Dessa forma, consideramos que o modelo representa uma primeira ferramenta de apoio ao acompanhamento dos preços dos combustíveis, mas suas estimativas devem ser utilizadas com cautela, não sendo recomendadas como única referência para decisões financeiras e operacionais.

● Declaração do Uso de IA Generativa

Durante o desenvolvimento do projeto, utilizamos o ChatGPT, ferramenta de inteligência artificial da OpenAI e a Ia do google GEMINI, como apoio na organização e estruturação das etapas do trabalho, na compreensão do funcionamento do modelo de Machine Learning e na interpretação das exigências de cada entrega.

A ferramenta também foi utilizada para auxiliar na identificação e correção de erros encontrados durante a implementação do código, além de contribuir para a revisão dos textos da documentação do projeto.

Ressaltamos que as sugestões fornecidas foram analisadas pela equipe, que permaneceu responsável pelas decisões tomadas, pela implementação e pela conferência dos resultados apresentados.

● Anexos e Documentação Complementar

Repositório do projeto: https://github.com/M-Eduarda-Souza/analise-de-combustiveis/tree/main

Notebook principa**l:**
https://github.com/M-Eduarda-Souza/analise-de-combustiveis/blob/main/notebooks/auditoria_dados.ipynb